



# 因果推理的下游应用

郑焕然





论文	发表会议	内容
《Counterfactual Data Augmentation for Neural Machine Translation》	NAACL (2021)	使用反事实推理进行机器翻译的数据增强
《Everything Has a Cause: Leveraging Causal Inference in Legal Text Analysis》	NAACL (2021)	使用因果推理来进行法律文本的分析



# Counterfactual Data Augmentation for Neural Machine Translation

**Qi Liu<sup>‡</sup>, Matt J. Kusner<sup>†\*</sup>, Phil Blunsom<sup>‡◇</sup>,**

<sup>‡</sup>University of Oxford <sup>◇</sup>DeepMind

<sup>†</sup>University College London <sup>\*</sup>The Alan Turing Institute

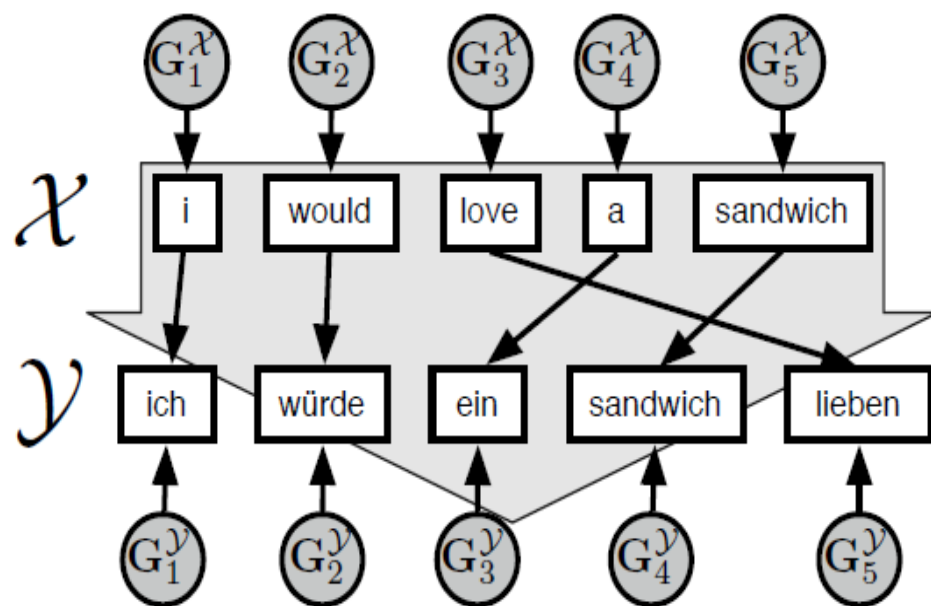
<sup>‡</sup>`{firstname.lastname}@cs.ox.ac.uk`

<sup>†</sup>`m.kusner@ucl.ac.uk`

1. 机器翻译模型需要依赖大规模平行语料才能实现优异的性能。并且机器翻译模型通常比较脆弱，会因为输入的噪音导致严重的误译现象。而数据增强是解决以上问题的一个好方法。
2. 之前的数据增强方法，要么忽略被替换单词的上下文，要么破坏源句和目标句之间的**对齐**，不利于生成高质量的数据。

本文将一个翻译语言模型视为一个结构因果模型，并提出了一个反事实问题：

给定源句和目标句，如果源序列中的一个短语被改变，那么目标句中与该短语对齐的短语将如何变化？




翻译语言模型:  $p(Y_j | \mathcal{X}, \mathcal{Y}_{-j})$

G: 未观测变量

在结构因果模型中进行反事实推理一般分为3步：

1. 外展 (Abduction) : 在给定所有观测变量 $V$ 的前提下，计算所有的非观测变量 $U$ 。
2. 干预 (Action) : 通过 $X=x$ , 来替换原来模型 $M$ 中的变量 $X$ , 从而修改原模型 $M$ 为  $M_x$  。
3. 预测 (Prediction) : 使用 $M_x$ 和第一步得到的 $U$ 来计算反事实结果。





$$X = U_X$$

$$H = aX + U_H$$

$$Y = bX + cH + U_Y$$

通过训练可以估计出: $a=0.5, b=0.7, c=0.4$ 。

假设对于某个学生李华, 我们观测到:


$X=0.5, H=1, Y=1.5$ , 那么假如他家庭作业的量翻倍, 他的考试成绩会是多少?

1. 外展 (Abduction):

$$U_X = 0.5$$


$$U_H = 1 - 0.5 \cdot 0.5 = 0.75$$

$$U_Y = 1.5 - 0.7 \cdot 0.5 - 0.4 \cdot 1 = 0.75$$



$$\begin{aligned}X &= U_X \\ H &= aX + U_H \\ Y &= bX + cH + U_Y\end{aligned}$$

2. 干预 (Action):

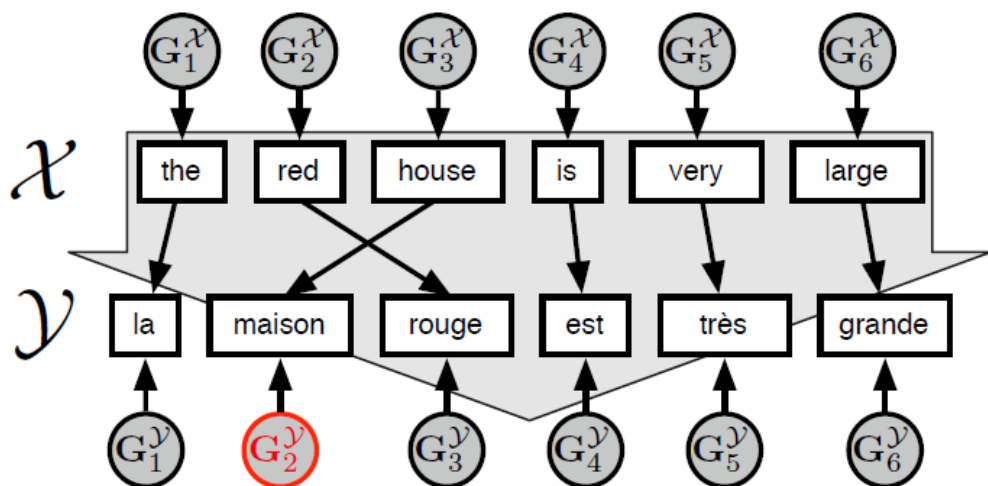


3. 预测 (Prediction):

$$\begin{aligned}Y_{H=2}(U_X = 0.5, U_H = 0.75, U_Y = 0.75) \\ = 0.5 \times 0.7 + 2 \times 0.4 + 0.75 = 1.90\end{aligned}$$



## 1. Abduction $p(G_2^y | \mathcal{X}, \mathcal{Y})$



本文假设每个G为一个Gumbel random vector

**Definition 3.1** (Gumbel-Max Trick). *Two steps are required to sample from a categorical distribution  $p(Y)$  with  $K$  categories: 1. Sample  $g_1, \dots, g_K \sim \text{Gumbel}(0, 1)$ . Each  $g_k$  can be computed as  $g_k = -\log(-\log u_k)$  where  $u_k \sim \text{Uniform}(0, 1)$ ; 2. Compute  $y = \arg \max_{k=1, \dots, K} \log p(Y = k) + g_k$ .*

## Algorithm 1: Gumbel Posterior Sampling

**Input** : The observed phrase  $y_j = k^*$   
Probabilities  $p(Y_j = k | \mathcal{X}, \mathcal{Y}_{-j})$   
for  $k = 1, \dots, |V|$

**Output** : Sampled Gumbel values

$$\hat{g} \sim p(G_j^y | \mathcal{X}, \mathcal{Y})$$

Sample  $\hat{g}_{k^*} \sim \text{Gumbel}(0, 1)$

**for**  $k \leftarrow 1$  **to**  $|V|$  **do**

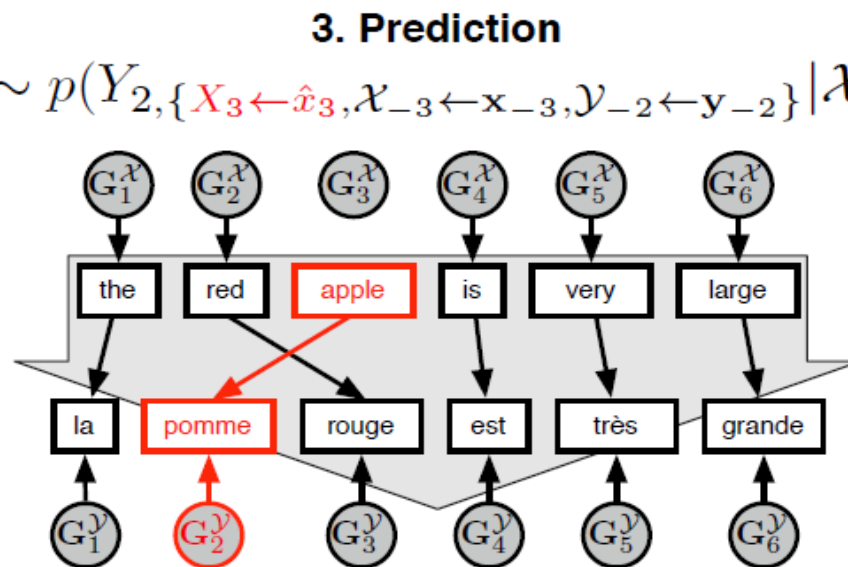
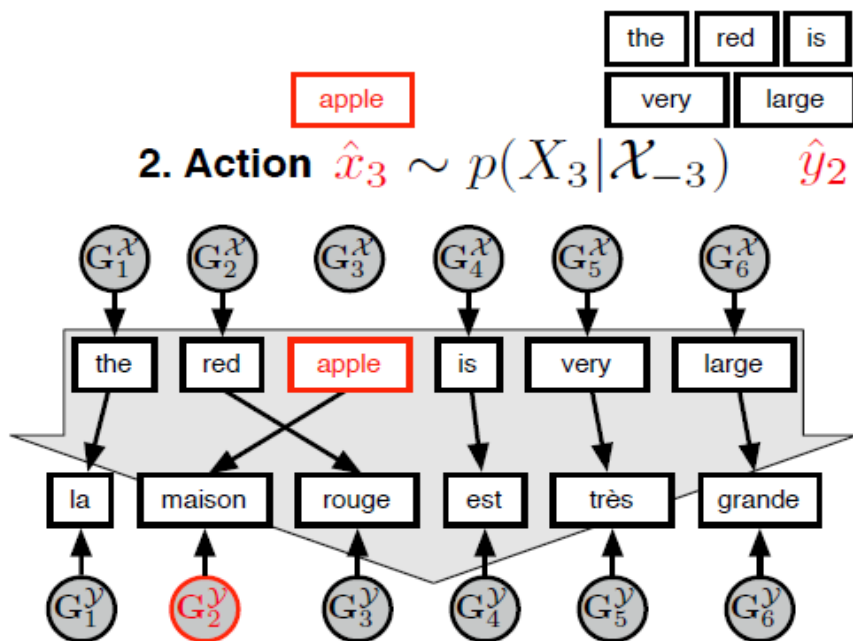
**if**  $k \neq k^*$  **then**

        // Sample from truncated Gumbel

        Sample  $h_k \sim \text{Gumbel}(0, 1)$

$$u_k = h_k + \log p(Y_j = k | \mathcal{X}, \mathcal{Y}_{-j})$$

$$\hat{g}_k = -\log(e^{-u_k} + e^{-\hat{g}_{k^*}})$$



2. 从预训练好的语言模型中采样出  $\hat{x}_3$   
并用其替换掉  $x_3$ 。

3. 重新预测  $y_2$  的值：

$$\hat{y}_2 = \arg \max_{k=1, \dots, |V|} \log p(Y_2 = k | \hat{x}_3, \mathcal{X}_{-3}, \mathcal{Y}_{-2}) + \hat{g}_k.$$

---

## Algorithm 2: Data Augmentation

---

**Input** :  $(\mathcal{X}, \mathcal{Y})$ : A sequence pair  
 $c$ : A sampling probability  
 $h$ : An alignment mapping

**Output**: A new pair  $(\hat{\mathcal{X}}, \hat{\mathcal{Y}})$   
 $\hat{\mathcal{X}}, \hat{\mathcal{Y}} = \mathcal{X}, \mathcal{Y}$   
**for**  $i \leftarrow 1$  **to**  $|\mathcal{X}|$  **do**  
    Sample  $u \sim \text{Uniform}(0, 1)$   
    **if**  $u < c$  **then**  
         $\hat{\mathcal{X}}, \hat{\mathcal{Y}} \leftarrow \text{replace}(\hat{\mathcal{X}}, \hat{\mathcal{Y}}, i, h)$

**Function**  $\text{replace}(\mathcal{X}, \mathcal{Y}, i, h)$   
    Get aligned index  $j = h(i)$   
     $\hat{\mathbf{g}} \sim p(\mathbf{G}_j^{\mathcal{Y}} | \mathcal{X}, \mathcal{Y})$   
     $\hat{x}_i \sim p(X_i | \mathcal{X}_{-i})$   
     $\hat{y}_j \sim$   
         $p(Y_j, \{X_i \leftarrow \hat{x}_i, \mathcal{X}_{-i} \leftarrow \mathbf{x}_{-i}, \mathcal{Y}_{-j} \leftarrow \mathbf{y}_{-j}\} | \mathcal{X}, \mathcal{Y})$   
    Set the  $i$ -th phrase of  $\mathcal{X}$  to  $\hat{x}_i$   
    Set the  $j$ -th phrase of  $\mathcal{Y}$  to  $\hat{y}_j$   
    **return**  $\mathcal{X}, \mathcal{Y}$

---

1.需要使用**pialign**来获取源句和目标句间的对齐关系。

2.需要预训练好的语言模型和翻译语言模型。

$$p_{\theta_1}(X_i | X_1, \dots, X_i = [\text{MASK}], \dots, X_{|\mathcal{X}|})$$

$$p_{\theta_2}(Y_j | \mathcal{X}, Y_1, \dots, Y_j = [\text{MASK}], \dots, Y_{|\mathcal{Y}|})$$

数据集：

Dataset	# Train	# Dev	# Test
WMT'18 En-Tr	206K	3007	3000
WMT'17 En-De	5.85M	2,999	3,004
IWSLT'15 En-Vi	133K	1,553	1,268
WMT'19 Robust En-Fr	36,058	852	1,401
Europarl-v7 En-Fr	2M	-	-

Table 2: The statistics of the parallel corpora.

主要实验结果：


Method	En $\rightarrow$ Tr	En $\rightarrow$ De	En $\rightarrow$ Vi
Baseline	15.35	27.54	31.66
+WordDropout	15.4	27.81	31.81
+SwitchOut	15.52	27.92	31.83
+SCDA	15.72	28.05	31.72
+TDA	15.69	28.16	31.79
+BPEDropout	15.95	28.29	33.59
+DADA	16.14	29.03	32.15
+TCWR	<b>17.38</b>	<b>29.37</b>	<b>33.76</b>

Method	En $\rightarrow$ Tr	En $\rightarrow$ De	En $\rightarrow$ Vi
Baseline	15.35	27.54	31.66
+TCWR	17.38	29.37	33.76
+BT	19.24	29.19	33.38
+BT +TCWR	<b>20.19</b>	<b>30.26</b>	<b>35.72</b>

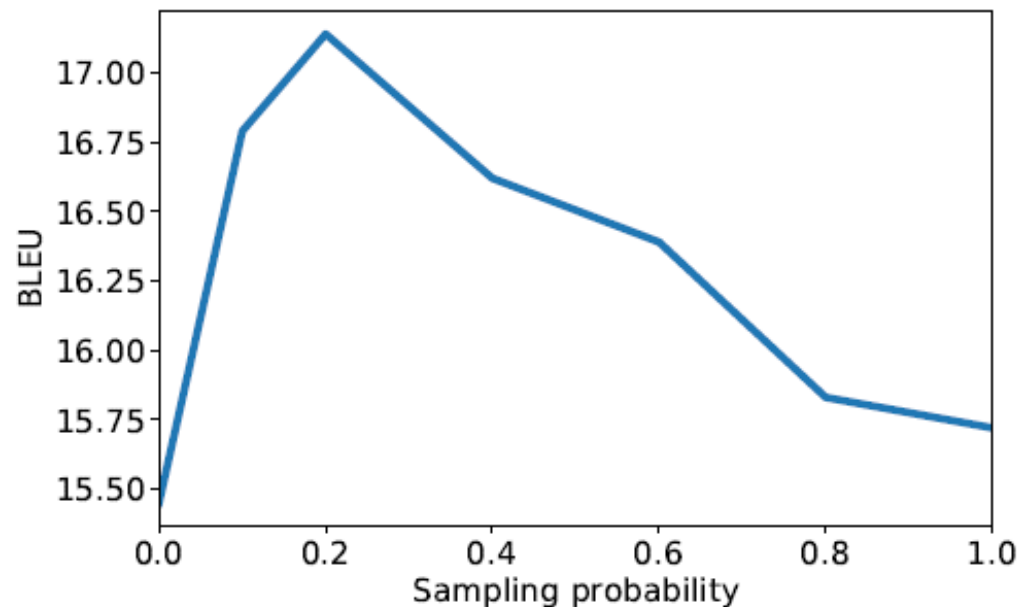
数据集：WMT'18 English -Turkish

预训练步数的影响：



当预训练步数达到一定阈值后，可能会出现过拟合现象，导致生成的数据的多样性和鲁棒性变差。

不同抽样概率 $c$ 的影响：



当 $c$ 在0.2左右时，BLEU的值最大。而之后随着 $c$ 的增大，翻译质量会明显下降，说明替换过多的token会导致生成的数据质量较差。

数据集: WMT'18 English -Turkish

Method	En $\rightarrow$ Tr
TCWR	17.49
-Source	16.47
-Target	16.29
-Alignment	16.59
-Gumbel	16.85

-Source:从均匀分布中随机采样token进行源句的替换。

-Target:从均匀分布中随机采样token进行目标句的替换。

-Alignment:在目标句中随机选取一个位置进行替换。

-Gumbel:将 $g_k$ 删除。



鲁棒性实验数据集： WMT'19 Robust En-Fr和  
Europarl-v7 En-Fr(用于训练)

Method	En → Fr
Baseline	26.0
+WordDropout	26.52
+SwitchOut	26.61
+SCDA	26.85
+BPEDropout	27.08
+TDA	27.11
+DADA	28.14
+TCWR	<b>28.92</b>

案例研究：

En:	Kosovo is taking a hard look at its privatisation process in light of recurring [complaints / <b>problems</b> ].
Tr:	Kosova, tekrar eden [şikayetler / <b>sorunlar</b> ] ışığında özelleştirme sürecini incelemeye alıyor.
En:	A decade later, we see that the [economy / <b>system</b> ] is terribly unstructured.
Tr:	On yıl sonra, [ekonominin / <b>sistemin</b> ] yapısının çok kötü bozulduğunu görüyoruz.
En:	Report : most [SEE / <b>independent</b> ] countries advance in economic freedom.
Tr:	Rapor : [GDA / <b>bağımsız</b> ] ülkelerinin çoğu ekonomik özgürlükte ilerliyor.

本文将反事实推理应用到了机器翻译的数据增强上。该方法能够同时考虑句子的上下文关系和对齐关系，使得生成的数据质量较高。

缺点：生成的数据与原先数据之间的差异性可能较小。并且需要依赖预训练的语言模型、翻译语言模型和对齐算法，生成数据的质量受它们的影响。

# Everything Has a Cause: Leveraging Causal Inference in Legal Text Analysis

**Xiao Liu<sup>1\*</sup>, Da Yin<sup>2\*</sup>, Yansong Feng<sup>1,3†</sup>, Yuting Wu<sup>1</sup> and Dongyan Zhao<sup>1,3</sup>**

<sup>1</sup>Wangxuan Institute of Computer Technology, Peking University, China

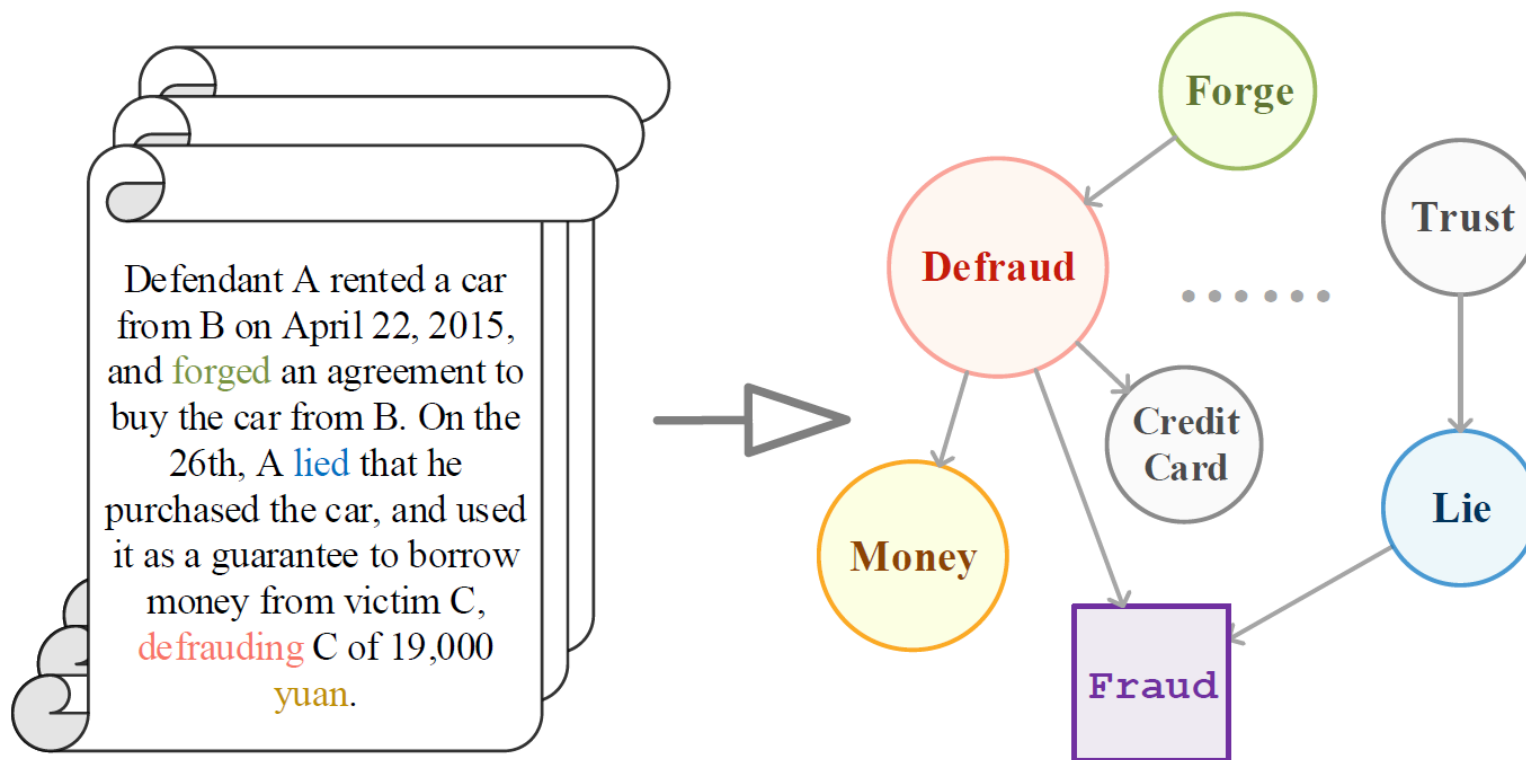
<sup>2</sup>Computer Science Department, University of California, Los Angeles

<sup>3</sup>The MOE Key Laboratory of Computational Linguistics, Peking University, China

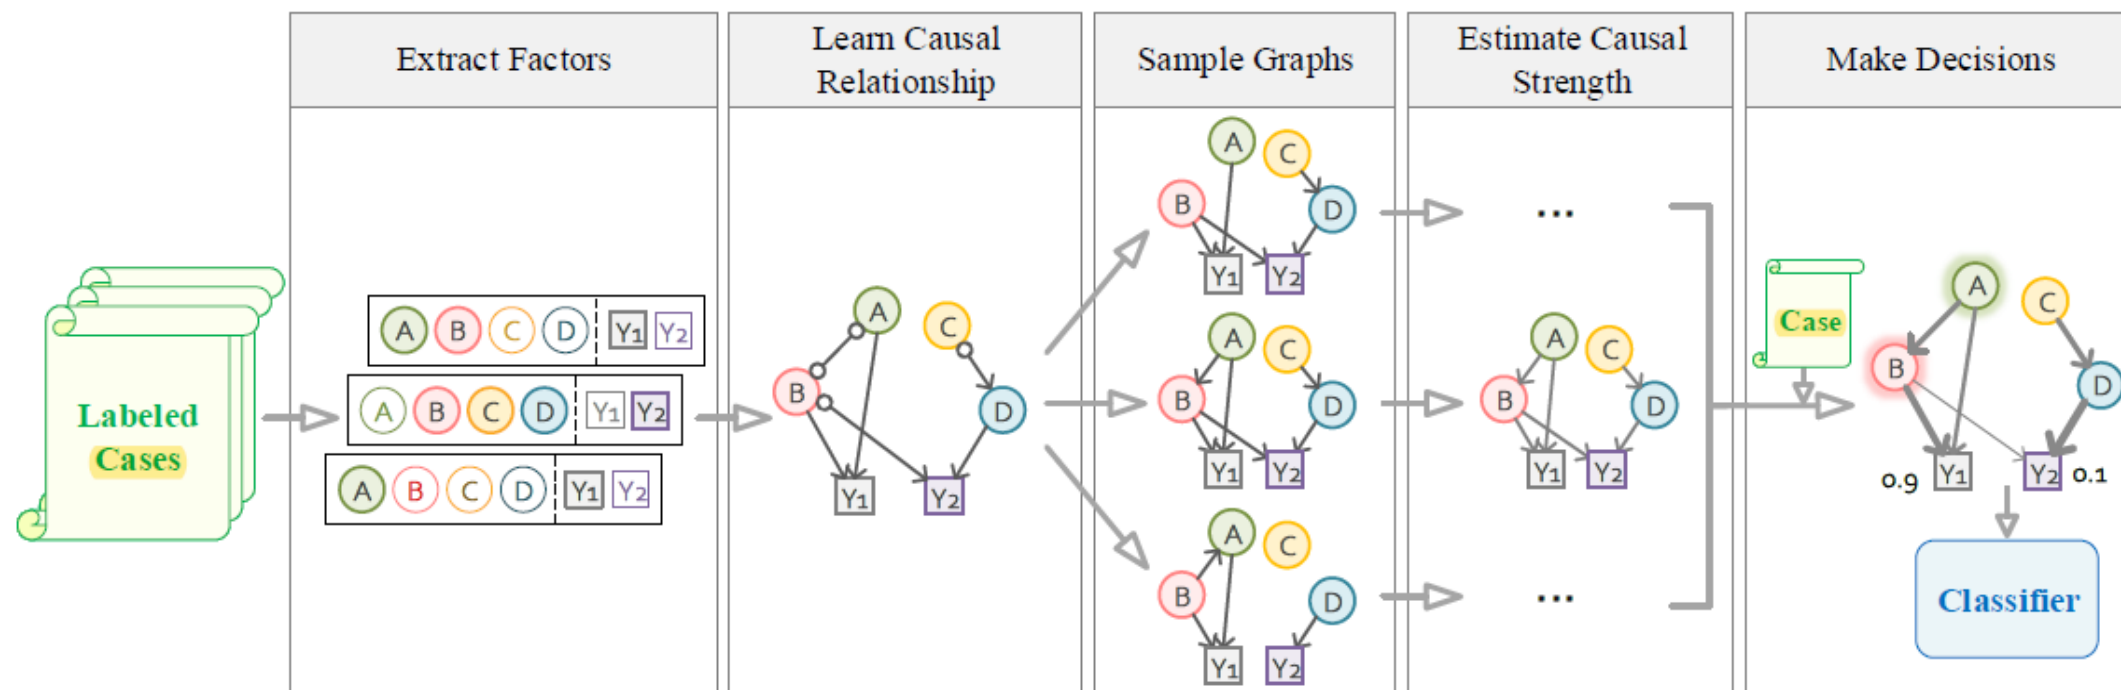
`{lxlisa, fengyansong, wyting, zhaody}@pku.edu.cn`

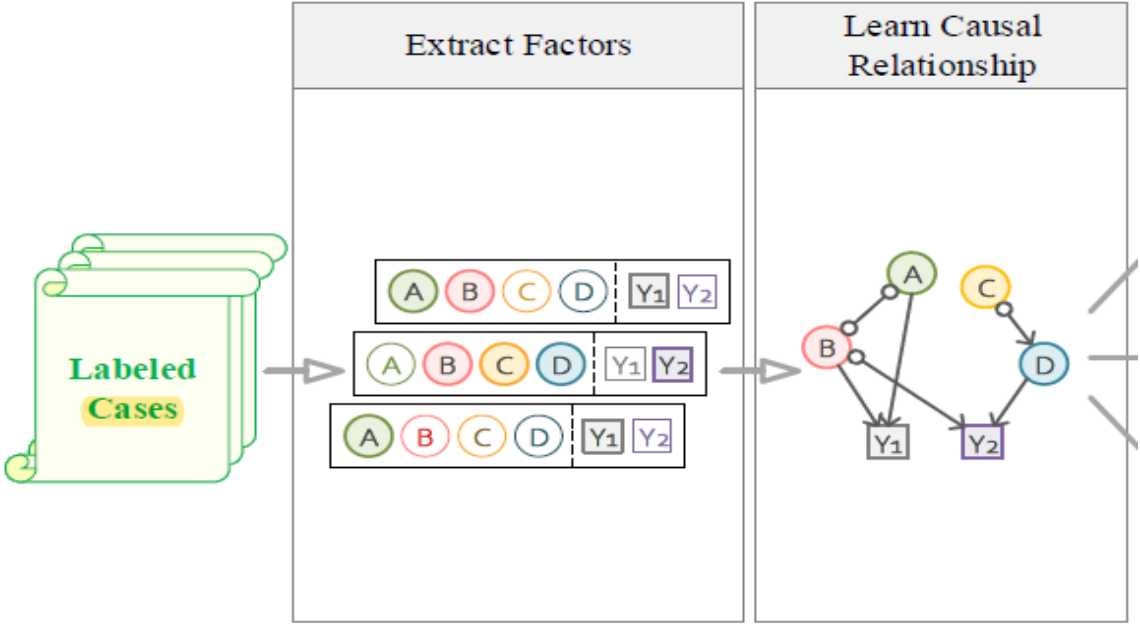
`da.yin@cs.ucla.edu`

1. 发现文本内部的因果关系可以帮助模型阅读综合性文本并做出相应决策。
2. 希望构建一个法律文本分析模型。其能够提供人类可读的、合理的解释，帮助法院做出正确的决定。



任务：辨别类似的charge。即给定案件的事实说明，模型需要在相似charge的集合中将每一个案件分类为一种确定的charge。





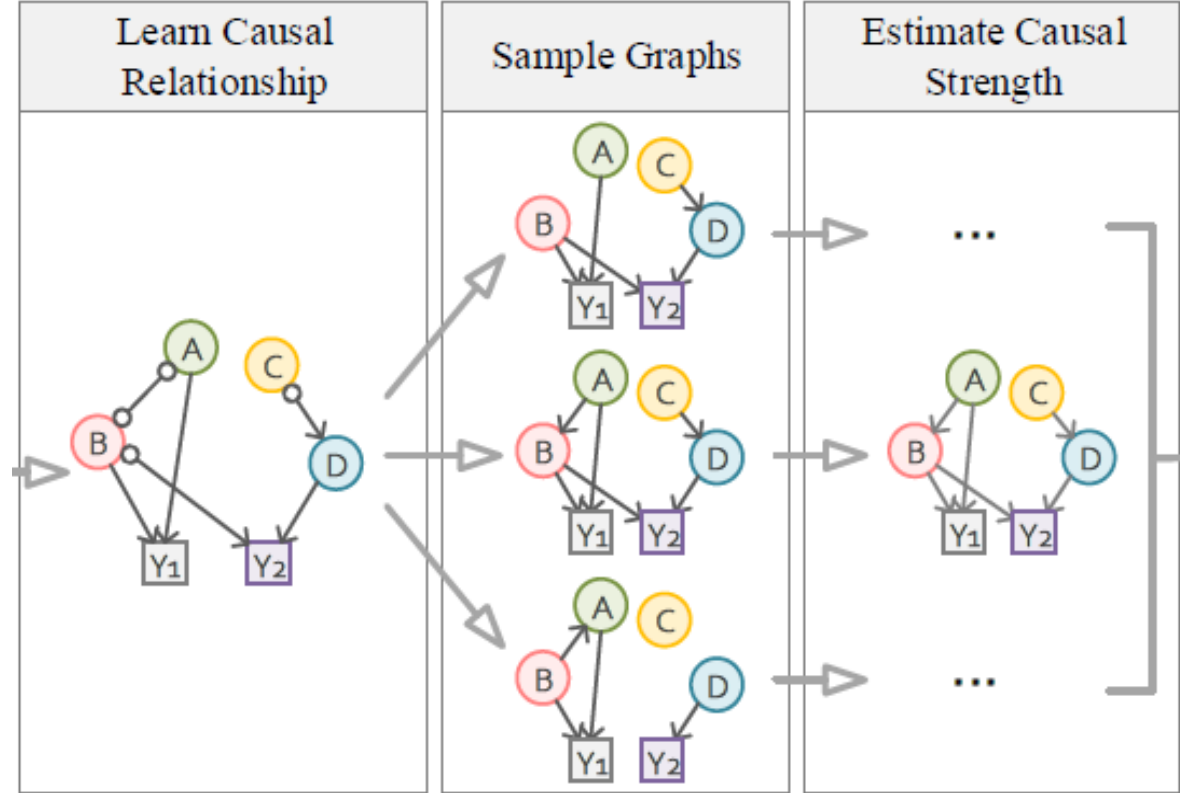
1.提取特征： 对于M个charge对应的多个Cases会使用YAKE为每一种charge提取p个关键词， 并使用聚类算法， 最终聚类出q个类别。然后使用q个类别和M个charge构成因果图的节点。将图应用于某个case时， 如果存在， 则节点的值1， 否则为0。

2.学习节点间的因果关系： 使用Greedy Fast Causal Inference(GFCI)算法发现不同节点间的因果关系。并且引入了两个约束来过滤噪声：

- (1)删除从charge到其他节点的边。
- (2)如果在大部分case中， 节点A出现在节点B之后， 则删除从A到B的边。法律文本中的事实描述通常是按照事件的时间顺序来写的。

Edge	Meaning
$A \rightarrow B$	A causes B.
$A \leftrightarrow B$	There is an unobserved confounder of A and B.
$A \circ \rightarrow B$	Either A causes B, or unobserved confounder.
$A \circ - \circ B$	Either A causes B, or B causes A, or unobserved confounder.





Edge	Meaning
$A \rightarrow B$	$A$ causes $B$ .
$A \leftrightarrow B$	There is an unobserved confounder of $A$ and $B$ .
$A \circ \rightarrow B$	Either $A$ causes $B$ , or unobserved confounder.
$A \circ - \circ B$	Either $A$ causes $B$ , or $B$ causes $A$ , or unobserved confounder.

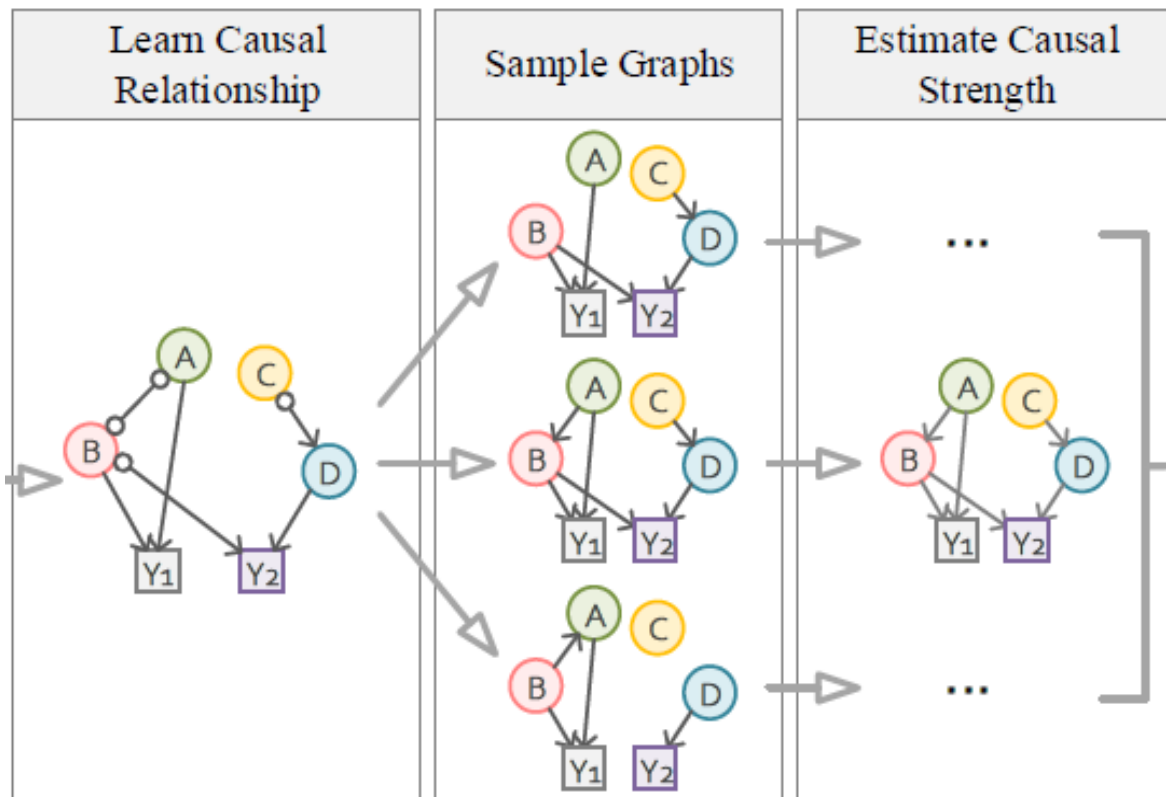
3.采样因果图：

对于->这类边， 将其保留。

对于<->这类边， 将其删除。

对于o->这类边， 有1/2的几率采样为->， 有1/2的几率将边删除。

对于o-o这类边， 有1/3的几率采样为->， 有1/3的几率采样为<-， 有1/3的几率将边删除。



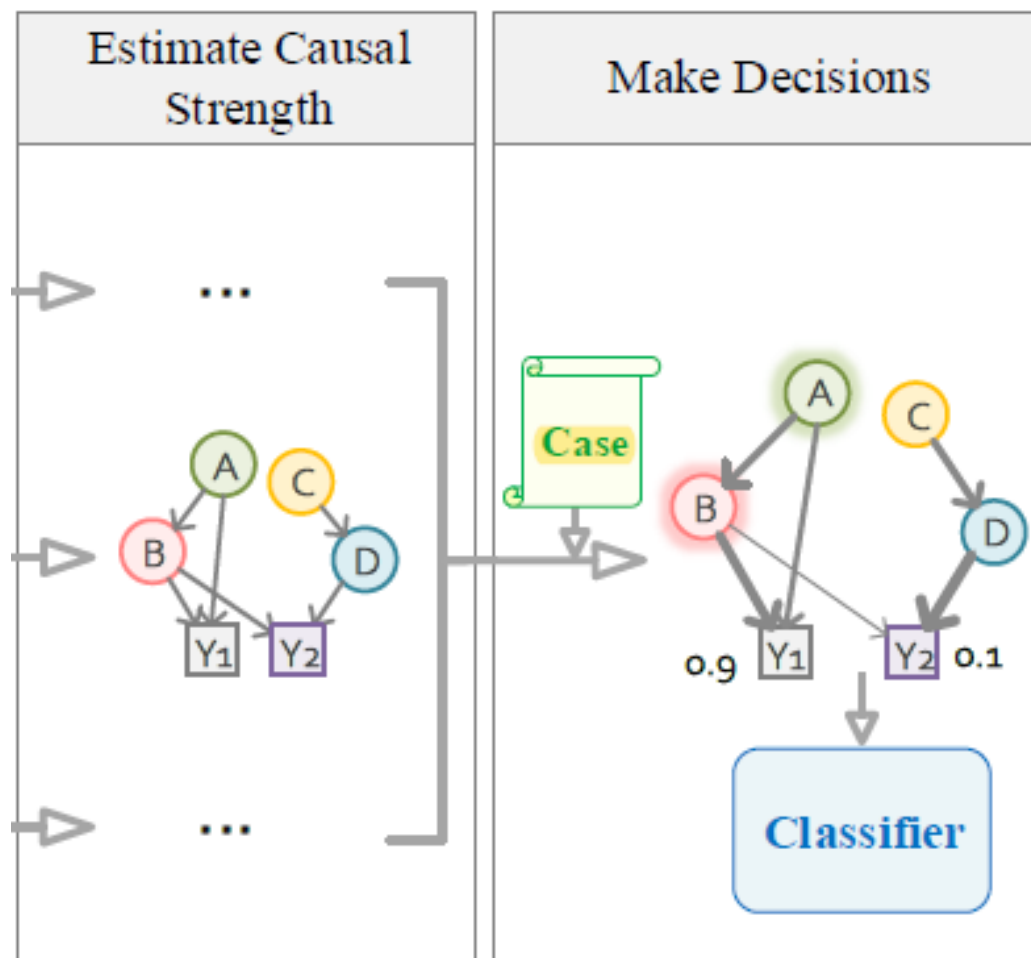
4.因果图的强度估计:

对于每个采样出的因果图G, 估计出每个Treatment T对于每个charge Y的因果关系强度:

$$\hat{\psi}_{T,Y}^G = [\sum_{i:t_i=1} (y_i - y_j) + \sum_{i:t_i=0} (y_j - y_i)]/N,$$

$$j = \operatorname{argmin}_{k:t_k \neq t_i} |L(z_i) - L(z_k)|$$

$$L(z) = P(T = 1 \mid Z = z)$$



5. 进行预测:

首先计算采样的所有因果图中的每个factor对于Y的因果影响强度:

$$\tilde{\psi}_{T_j, Y_i} = \sum_{q=1}^Q \text{BIC}(G_q, \mathbf{X}) \times \hat{\psi}_{T_j, Y_i}^{G_q},$$

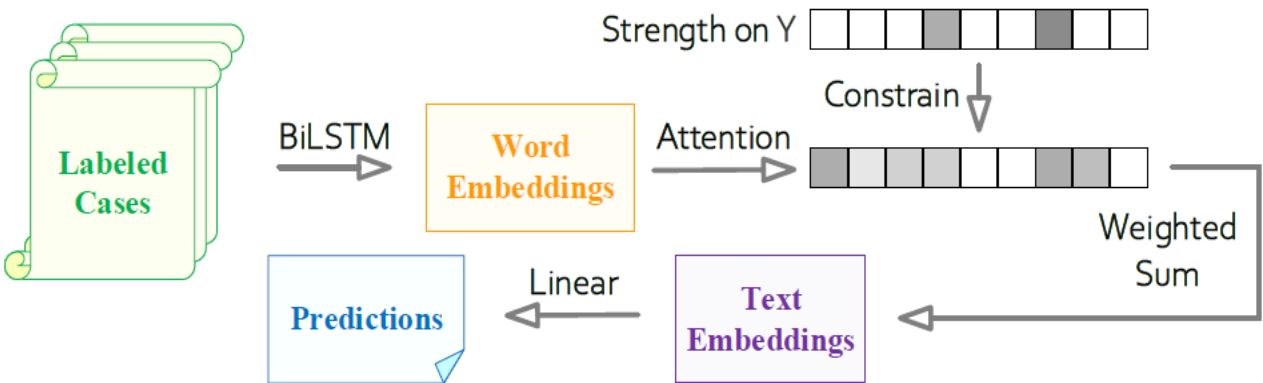
$$\text{BIC} = k \ln(n) - 2 \ln(L),$$

然后根据输入的Case计算每一种charge的得分:

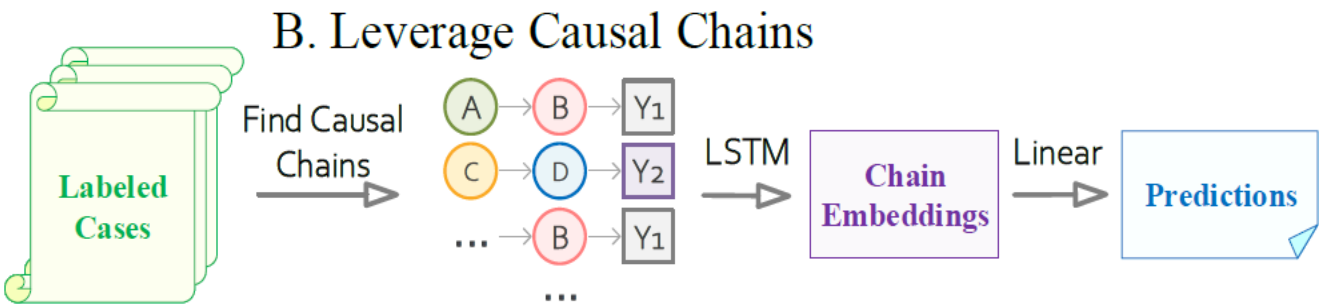
$$S(Y_i) = \sum_{T_j \in \text{Tr}(Y_i)} \tilde{\psi}_{T_j, Y_i} \times \tau(T_j), i \in \{1, \dots, M\},$$

$\tau(T_j)$  表示Tj是否存在于Case中。

最终将计数出的得分输入给随机森林进行分类。



A. Impose Strength Constraints



B. Leverage Causal Chains

A.引入估计的因果强度来约束带注意力机制的模型。

$$L_{cons} = \sum_{i=1}^n (a_i - g_i)^2,$$
$$L = L_{cross} + \alpha L_{cons}.$$

B. 使用因果链代替输入的文本。

$$\mathbf{ch}_i = \sum_{j=1}^{l_i} (\text{LSTM}(\text{chain}_i)_j),$$
$$\mathbf{c} = \text{MaxPooling}(\text{BIC}(G_q, \mathbf{X}) \times \mathbf{ch}_i),$$
$$1 \leq i \leq m, \text{ chain}_i \in G_q,$$

数据集：CAIL2018(Chinese AI and Law Challenge2018)

Charge Sets	Charges	#Cases
Personal Injury	Intentional Injury & Murder & Involuntary Manslaughter	6377 / 2282 / 1989
Violent Acquisition	Robbery & Seizure & Kidnapping	5020 / 2113 / 622
F&E	Fraud & Extortion	3536 / 2149
E&MPF	Embezzlement & Misappropriation of Public Funds	2391 / 1998
AP&DD	Abuse of Power & Dereliction of Duty	1950 / 1938

Table 2: Summary of the similar charge sets.

Models		Personal Injury	Violent Acquisition	F&E	E&MPF	AP&DD	Average
LSTM	1%	60.94 / 37.91	58.48 / 29.33	63.91 / 47.00	53.56 / 39.84	52.08 / 46.13	57.79 / 40.04
	5%	61.97 / 44.88	67.09 / 35.86	71.60 / 68.68	59.89 / 56.88	54.12 / 48.53	62.93 / 50.97
	10%	76.45 / 67.81	65.64 / 47.62	82.14 / 80.74	70.21 / 70.00	55.46 / 51.29	69.98 / 63.49
	30%	85.37 / 81.27	74.43 / 66.05	88.10 / 87.33	71.60 / 70.82	65.61 / 65.19	77.02 / 74.13
	50%	85.67 / 83.02	80.10 / 72.27	90.04 / 89.06	75.59 / 75.46	69.65 / 69.62	80.21 / 77.89
Bi-LSTM	1%	62.29 / 40.81	53.86 / 33.25	62.95 / 43.27	54.54 / 41.91	48.98 / 37.84	56.52 / 39.42
	5%	74.00 / 69.52	65.18 / 38.99	60.34 / 56.96	61.88 / 61.63	51.77 / 46.23	62.63 / 54.66
	10%	76.66 / 71.86	67.10 / 46.07	85.31 / 84.37	60.08 / 53.34	60.20 / 57.95	69.87 / 62.72
	30%	85.46 / 82.53	75.30 / 64.12	87.57 / 86.58	70.45 / 69.64	65.45 / 65.12	76.85 / 73.60
	50%	87.19 / 85.01	78.43 / 69.94	90.43 / 89.83	76.08 / 75.78	71.12 / 70.50	80.65 / 78.21
GCI	1%	69.54 / 49.77	57.08 / 42.55	82.81* / 82.56*	74.65* / 70.22*	62.47 / 61.72	69.31* / 61.36*
	5%	81.19 / 75.58	69.70 / 60.39 <sup>†</sup>	88.25 / 87.24 <sup>†</sup>	83.27 <sup>†</sup> / 83.06 <sup>†</sup>	78.09 <sup>†</sup> / 77.95 <sup>†</sup>	80.10 <sup>†</sup> / 76.84 <sup>†</sup>
	10%	80.33 / 74.50	74.06 / 67.31 <sup>§</sup>	87.97 / 87.51	85.23 <sup>§</sup> / 84.62 <sup>§</sup>	78.36 <sup>§</sup> / 78.31 <sup>§</sup>	81.19 <sup>§</sup> / 78.45 <sup>§</sup>
	30%	84.83 / 80.10	75.99 / 70.64	89.31 / 88.39	88.55 <sup>‡</sup> / 88.21 <sup>‡</sup>	80.82 / 80.56 <sup>‡</sup>	83.90 <sup>‡</sup> / 81.58 <sup>‡</sup>
	50%	85.72 / 81.62	76.31 / 71.45	90.41 / 89.14	89.01 <sup>‡</sup> / 88.63 <sup>‡</sup>	81.01 <sup>‡</sup> / 80.90 <sup>‡</sup>	84.49 / 82.35
GCI-co	1%	67.49 / 44.43	63.70* / 34.64	75.72 / 67.60	69.08 / 67.20	64.93* / 64.41*	68.19 / 55.66
	5%	76.70 / 63.94	67.65 / 34.35	86.63 / 85.81	82.23 / 81.86	73.94 / 73.77	77.43 / 67.95
	10%	68.05 / 45.37	69.26 / 46.39	85.62 / 84.41	81.23 / 79.64	74.21 / 74.05	75.67 / 65.97
	30%	77.31 / 63.45	70.42 / 50.94	81.44 / 80.54	85.71 / 85.20	74.43 / 74.28	77.86 / 70.88
	50%	79.21 / 69.37	70.38 / 50.78	79.30 / 77.58	84.39 / 83.72	74.16 / 73.99	77.49 / 71.09
CausalChain	1%	73.20* / 60.31*	63.60 / 44.02*	68.01 / 52.93	66.97 / 56.66	63.13 / 62.30	66.98 / 55.24
	5%	81.99 <sup>†</sup> / 76.03 <sup>†</sup>	70.57 / 59.85	88.64 <sup>†</sup> / 87.21	75.13 / 74.74	71.75 / 70.38	77.62 / 73.64
	10%	81.21 / 74.71	73.50 / 66.66	87.59 / 86.36	79.75 / 79.45	74.43 / 74.11	79.30 / 76.26
	30%	85.61 / 81.00	74.93 / 67.30	89.10 / 88.19	81.63 / 81.25	80.90 <sup>‡</sup> / 80.50	82.43 / 79.65
	50%	86.41 / 83.11	75.66 / 68.47	90.45 / 89.21	81.25 / 80.09	80.03 / 79.89	82.76 / 80.16
Bi-LSTM+Att	1%	62.16 / 41.70	58.21 / 32.97	67.99 / 62.80	57.90 / 50.67	53.20 / 41.78	59.89 / 45.99
	5%	78.29 / 72.81	67.50 / 50.68	85.30 / 84.28	61.86 / 55.38	58.76 / 53.03	70.34 / 63.23
	10%	81.51 / 78.36	67.97 / 58.26	88.07 / 87.33	75.38 / 74.86	58.82 / 55.82	74.35 / 70.93
	30%	86.07 / 83.49	80.47 / 72.55	88.97 / 88.41	81.53 / 81.14	72.84 / 72.65	81.98 / 79.65
	50%	87.25 / 85.38	82.27 / 74.15	91.56 / 91.05	82.29 / 82.11	73.70 / 73.65	83.41 / 81.27
Bi-LSTM+Att +Cons	1%	70.12 / 59.46	54.29 / 40.34	78.25 / 76.80	61.03 / 60.62	53.84 / 44.93	63.51 / 56.43
	5%	79.07 / 75.89	73.09 <sup>†</sup> / 56.84	86.80 / 86.35	66.86 / 59.89	72.27 / 72.18	75.62 / 70.23
	10%	83.33 <sup>§</sup> / 79.70 <sup>§</sup>	76.26 <sup>§</sup> / 64.62	88.76 <sup>§</sup> / 88.02 <sup>§</sup>	80.03 / 79.64	73.53 / 73.48	80.38 / 77.09
	30%	86.55 <sup>‡</sup> / 83.85 <sup>‡</sup>	81.48 <sup>‡</sup> / 73.15 <sup>‡</sup>	89.80 <sup>‡</sup> / 89.35 <sup>‡</sup>	81.82 / 81.31	79.46 / 79.35	83.82 / 81.40
	50%	88.31 <sup>‡</sup> / 86.18 <sup>‡</sup>	82.72 <sup>‡</sup> / 76.03 <sup>‡</sup>	92.05 <sup>‡</sup> / 91.55 <sup>‡</sup>	83.02 / 82.69	80.72 / 80.64	85.36 <sup>‡</sup> / 83.42 <sup>‡</sup>

1.Causal Graph vs. Correlation-based Graph.

GCI-co是基于相关性建图。通过挖掘因果关系构建的图能更好地反映charges与factors之间的关系。

2. Causal Inference vs. Neural Networks.

对于低资源场景， GCI的性能更好， 而随着训练数据的增加， NN的性能逐渐提升， 两者差距不断减小。

3.加入因果强度约束有助于基于注意力机制的模型捕捉文本中的关键信息。

4.因果链中包含了有助于判断的关键信息， 而整个描述中包含的不相关信息较多， 可能会干扰预测。



## 1. 因果图的质量：




Figure 4: An example of sensitivity analysis for treatments of `extortion` in the causal graph of F&E.

**Random Confounder:** 在图中加入一个新的随机值，理想情况下，因果强度应该保持不变。

**Placebo Treatment:** `Treatment`的值被一个随机值代替，理想情况下因果强度应该为零。

**Subset of Data:** 使用`cases`的子集重新计算强度。理想情况下，强度估计不会有显著变化。

## 2. 因果图中的因果链：

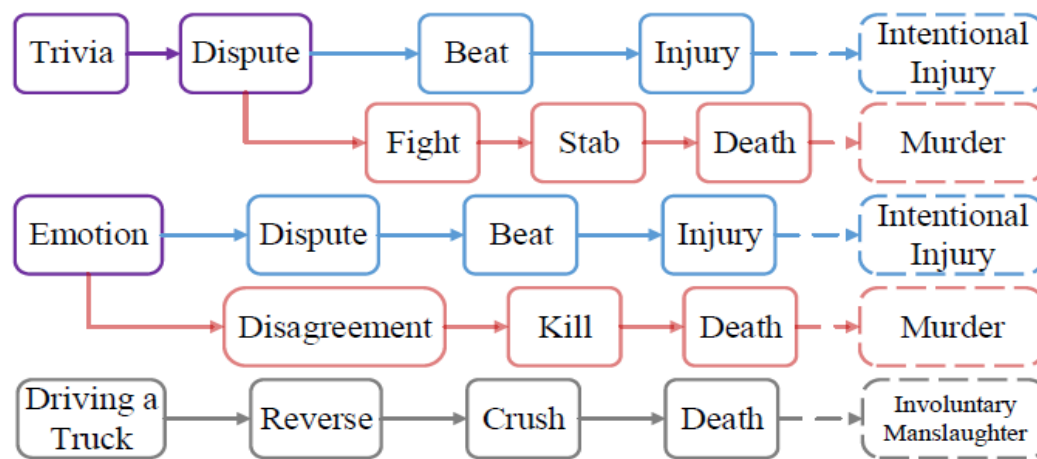


Figure 5: Causal chains in Personal Injury's graph.

这些因果链描绘了对应`charge`的共同模式，从最初的原因到最终的犯罪行为。有助于人们更好地理解法律案件的核心部分。

2.因果图中的因果链可以帮助区分相似的charge。

E&MPF	work → take advantage of (position/power) → embezzlement
	falsely report → arbitrage → embezzlement
	take charge of → take advantage of (position/power)→ misappropriate → profit
	→ misappropriation of public funds

embezzlement强调某人私下非法持有大量资金，而misappropriation强调在一定时间内将资金用于特定目的。所以区别在于这个人是否有后续行为(如将钱用于盈利等)。

3.因果强度约束的效果。

随机选择两个模型都能正确预测的150个case，分别展示内容、charge和注意力权重在0.05以上的词语。人工对这些词语进行1-5的打分，分数越高意味着注意力权重确实抓住了关键字。

Charge Sets	<i>Bi-LSTM+Att</i>	<i>Bi-LSTM+Att+Cons</i>
Personal Injury	3.03	<b>3.17</b>
Violent Acquisition	3.18	<b>3.74</b>
F&E	3.34	<b>3.65</b>
E&MPF	3.13	<b>3.27</b>
AP&DD	3.08	<b>3.13</b>

本文提出了一种新的基于图的因果推理框架GCI，将因果推理应用于法律文本的分析。并且还提出了两种方法，可以将GCI产生的结果与神经网络相结合，从而提高神经网络的性能。

通过因果推理的方法，不仅可以提高模型预测的性能，并且还可以为输出人类可读的、合理的因果链，增强了模型的可解释性。

缺点：自动化生成因果图的过程可能会带来不准确的因素,甚至遗漏关键因素。该方法难以处理复杂的case描述，比如：难以分辨否定语气、出现代词混淆现象等。



谢谢  
Thank You